

Projet Master 1 IC

Titre du sujet: Benchmark d'approches de transcription automatique de conférences relatives au domaine musical

Nom de l'encadrant: Solenn Tual, Cassia Trojahn

Email de l'encadrant: solenn.tual@inria.fr,

Téléphone de l'encadrant:

1. Présentation du sujet

(merci de nous faire parvenir le document dans un format éditable)

1. Contexte du projet

La Philharmonie de Paris – Cité de la Musique conserve des centaines d'heures d'enregistrements audio et vidéo de conférences sur la musique. Principalement en français, ces interventions (*keynotes*, tables rondes, etc.) font intervenir un nombre variable d'orateurs et comportent parfois des interventions dans d'autres langues.

Actuellement, ces ressources sont associées à des métadonnées globales (titre, résumé, mots-clés) qui permettent une recherche générale. Cependant, ces données ne permettent pas de cibler des extraits précis au sein des enregistrements.

Pour répondre à ce besoin, une application de recherche d'extraits pertinents est en cours de développement. Elle s'appuie sur les transcriptions textuelles des conférences, générées au préalable par le modèle de reconnaissance automatique de la parole (ASR) WhisperX [1]. L'outil explore deux approches complémentaires :

- Une recherche sémantique (*dense retrieval*) : comparaison d'embeddings de texte entre la requête utilisateur et les paragraphes des transcriptions.
- Une recherche par entités nommées : interrogation d'index regroupant des personnes (musiciens, compositeurs etc.), des œuvres, des termes musicaux (instruments, genres), des lieux ou des organisations.

2. Verrou scientifique et technique

La qualité des extraits restitués dans l'application actuelle, ainsi que l'exhaustivité des index d'entités, est fortement impactée par les erreurs de transcription du modèle ASR. Ces dernières altèrent particulièrement les noms propres et le vocabulaire spécialisé [2] présents dans le texte. Ces erreurs initiales se propagent en cascade dans la chaîne de traitement et dégradent les performances des tâches aval, notamment la reconnaissance d'entités nommées (NER).

Le projet de recherche Music Graph RAG (MGR) (Inria, Philharmonie de Paris) vise à proposer des approches innovantes de recherche sémantique dans le corpus de conférences qui réduisent l'effet des erreurs de transcription (« bruit ASR ») sur la

qualité des résultats obtenus (index d'entités constituées et extraits retournés à l'utilisateur).

3. Sujet du projet

Dans ce cadre, le sujet de ce projet IC vise à évaluer et comparer les performances de différentes modèles *reconnaissance automatique du langage (ASR)* appliquées aux conférences enregistrées par la Philharmonie de Paris – Cité de la Musique. Il comprend plusieurs axes de recherche qui pourront être traités successivement ou en parallèle une fois le projet débuté (point 3.1).

Un jeu de données d'évaluation comprenant 3 conférences (env. 3h30 d'audio) a fait l'objet d'une correction manuelle du texte, de l'historisation des orateurs et de l'annotation des entités nommées. Il sera utilisé comme jeu de données initial pour l'évaluation des modèles utilisés. Les étudiants disposeront également de plusieurs centaines d'heures de conférences audio, de leur transcription automatique avec WhisperX et de leurs métadonnées.

3.1. Comparaison des performances de modèles ASR pour la transcription

Ce premier axe du projet vise à implémenter plusieurs modèles de transcription (*Speech-to-text*) à l'état de l'art et à comparer leurs performances sur plusieurs jeux de données d'évaluation en français. Les modèles et outils testés doivent être disponibles en *open-source* ou en *open-weight*, notamment, [Qwen3-ASR](#) [3] et [Voxtral](#) [4]. Les étudiants sont invités à proposer d'autres modèles à l'état de l'art répondant à ce critère. Ce benchmark devra également de comparer les résultats de ces modèles à la *baseline* établie avec *WhisperX* [1].

Les métriques utilisées pour l'évaluation sont le *Word Error Rate* (WER) et le *Character Error Rate* (CER) [5]. Elles devront être calculées pour la transcription complète ainsi que spécifiquement pour les entités nommées. Pour calculer ces indicateurs, les transcriptions générées automatiquement devront être alignées avec le texte corrigé. L'approche choisie pourra mobiliser différents paramètres (synchronisation temporelle audio/texte, similarité entre le texte prédit et la référence).

3.2. Reconnaissance des entités nommées dans les processus de transcription ou de post-correction

Un des principaux objectif du projet MGR est de rechercher et d'indexer efficacement les entités nommées mentionnées dans les conférences. Ceci implique de disposer d'une transcription performante de ces entités.

Des approches de post-correction ASR comme DeRAGEC [6] proposent de cibler spécifiquement les entités nommées pour améliorer localement la qualité des transcriptions en mobilisant les caractéristiques phonétiques du texte. D'autres approches récentes comme WhisperNER [8] proposent de réaliser la tâche de NER simultanément avec la tâche de transcription dans le but de réduire la propagation des erreurs d'une tâche à une autre et de capitaliser sur les informations contenues dans l'audio pour améliorer la détection.

Il serait particulièrement intéressant de comparer les résultats obtenus par les approches de transcription classique (point 3.1) aux approches qui détectent/intègrent les entités nommées en phase de transcription initiale ou en post-correction (point 3.2).

3.3 Développement du jeu de données d'évaluation

Le jeu de données d'évaluation actuellement disponible est de taille et de variété thématique restreinte. La correction manuelle des transcriptions est un particulièrement chronophage. L'évaluation d'une ou plusieurs approches automatiques de post-correction ASR appliqués aux sorties produites avec différents modèles au point 1 serait donc particulièrement intéressante, afin d'évaluer la pertinence d'utiliser ce type d'approche pour (1) améliorer globalement les transcriptions et (2) accélérer l'accroissement du jeu de données d'évaluation avec de nouvelles conférences/extraits de conférences.

Une application dédiée à la post-correction manuelle et à l'annotation des conférences (orateurs, NER, liage d'entités) a été développée dans le cadre du projet MGR et pourra être utilisée pour valider manuellement les résultats obtenus pour quelques conférences supplémentaires.

4. Attendus techniques

Les expériences de ce projet informatique seront implémentées en Python. Le code doit être documenté et modulable pour intégrer ultérieurement de nouveaux modèles et outils et pouvoir comparer leurs résultats à ceux des approches qui seront implémentées dans le cadre du projet. L'ajout de différents jeux de données doit également être possible.

Le code doit inclure la génération de tableaux de résultats qui restituent l'évaluation des approches implémentées, avec les différentes métriques.

2. Références

[1] Bain, Max, Jaesung Huh, Tengda Han, et Andrew Zisserman. « WhisperX: Time-Accurate Speech Transcription of Long-Form Audio ». arXiv:2303.00747. Prépublication, arXiv, 2023. <https://doi.org/10.48550/arXiv.2303.00747>.

[2] Szymański, Piotr, Lukasz Augustyniak, Mikolaj Morzy, Adrian Szymczak, Krzysztof Surdyk, et Piotr Żelasko. « Why Aren't We NER Yet? Artifacts of ASR Errors in Named Entity Recognition in Spontaneous Speech Transcripts ». In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2023. <https://doi.org/10.18653/v1/2023.acl-long.98>.

[3] Shi, Xian, Xiong Wang, Zhifang Guo, et al. « Qwen3-ASR Technical Report ». arXiv:2601.21337. Prépublication, arXiv, 2026. <https://doi.org/10.48550/arXiv.2601.21337>.

[4] Liu, Alexander H., Andy Ehrenberg, Andy Lo, et al. « Voxtral ». arXiv:2507.13264. Prépublication, arXiv, 2025. <https://doi.org/10.48550/arXiv.2507.13264>.

[5] jiwer: simple and fast python package to evaluate an automatic speech recognition system. <https://jitsi.github.io/jiwer/>.

[6] Im, Solee, Wonjun Lee, JinMyeong An, Yunsu Kim, Jungseul Ok, et Gary Lee. « DeRAGEC: Denoising Named Entity Candidates with Synthetic Rationale for ASR Error Correction ». In *Findings of the Association for Computational Linguistics: ACL 2025*. Association for Computational Linguistics, 2025. <https://doi.org/10.18653/v1/2025.findings-acl.786>.

[8] Ayache, Gil, Menachem Pirchi, Aviv Navon, Aviv Shamsian, Gill Hetz, et Joseph Keshet. « WhisperNER: Unified Open Named Entity and Speech Recognition ». arXiv:2409.08107. IEEE ASRU 2025. <https://doi.org/10.48550/arXiv.2409.08107>.

3. Positionnement du sujet

- Indiquez le niveau d'innovation du sujet proposé
Très innovant ☐ ☒ ☐ ☐ ☐ Classique
- Indiquez la disponibilité de la documentation relative aux technologies à mettre en œuvre
Beaucoup ☐ ☒ ☐ ☐ ☐ Aucune
- Indiquez le niveau d'abstraction du sujet
Théorique ☐ ☐ ☐ ☒ ☐ Pratique
- Indiquez la quantité de développement à réaliser
Beaucoup ☐ ☒ ☐ ☐ ☐ Peu
- Indiquez le niveau de difficulté des algorithmes à mettre en œuvre
Difficile ☐ ☐ ☒ ☐ ☐ Facile
- Indiquez le niveau d'interaction avec d'autres composants logiciels
Ecosystème complexe ☐ ☒ ☐ ☐ ☐ Application seule
- Indiquez le nombre d'étudiants souhaités pour le projet : 3
- Indiquez les langages et technologies à utiliser:
 - Langage : Python
 - Bibliothèques orientées deep learning (liste non exhaustive) : transformers, vLLM, Ollama, PyTorch
 - Utilisation d'un serveur de calcul GPU avec gestionnaire de jobs (OAR)

4. Encadrement

- Combien de temps pouvez-vous consacrer à l'encadrement de projets chaque semaine ?
 - * Solenn Tual : 1 heure (ou 2 heures périodiquement)
- Indiquez vos contraintes quant à l'encadrement
 - * Solenn Tual : Localisation administrative à Inria à Montbonnot Saint-Martin.
- Indiquez vos contraintes quant au sujet proposé
 - * Utilisation d'outils et de modèles open source (ou open weights pour certains modèles).
 - * Le choix des modèles utilisés peut être conditionné par les capacités du serveur de calcul.

A retourner à :

Damien.Pellier@univ-grenoble-alpes.fr